


Técnicas para calcular distribuciones de creencias honestas

Gustavo Landfried

@GALandfried 

Licenciado en Ciencias Antropológicas
Doctorando en Ciencias de la Computación



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Incertidumbre



Sorpresa



Sorpresa

El punto débil de las creencias



¿Cómo estimar habilidades?




Arpad Elo

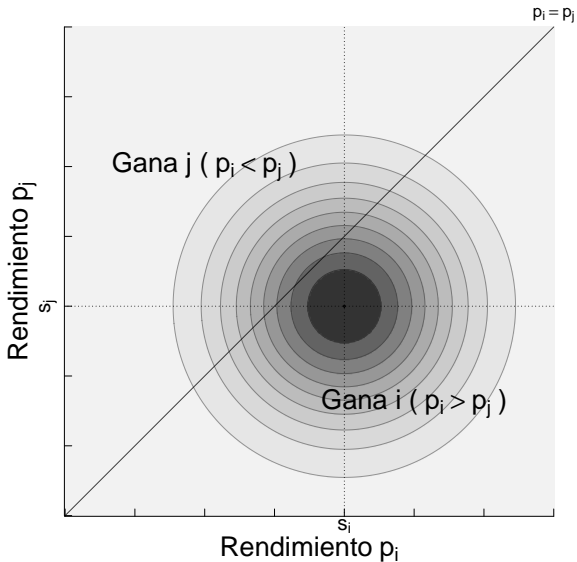
Modelo Elo

Rendimiento aleatorio oculto (p)
centrado en la habilidad estimada (s)

Resultado observado (r)



Probabilidad de ganar (gráfica)



Estimación Elo

$$s_i^{\text{new}} = s_i^{\text{old}} + K\Delta$$

Estimación Elo

$$s_i^{\text{new}} = s_i^{\text{old}} + K\Delta$$


$$\Delta = \underbrace{(2r_{ij} - 1)}_{\text{Signo del resultado}} \underbrace{(1 - P(r_{ij}|s_i, s_j))}_{\text{Sorpresa del resultado}}$$

Estimación Elo

$$s_i^{\text{new}} = s_i^{\text{old}} + K\Delta$$

$$\Delta = \underbrace{(2r_{ij} - 1)}_{\text{Signo del resultado}} \underbrace{(1 - P(r_{ij}|s_i, s_j))}_{\text{Sorpresa del resultado}}$$

Modelo de solución



Hoy

Estimación de habilidad en la industria del video juego



Hoy

Estimación de habilidad en la industria del video juego




Inferencia Bayesiana

¿Por qué inferencia Bayesiana?

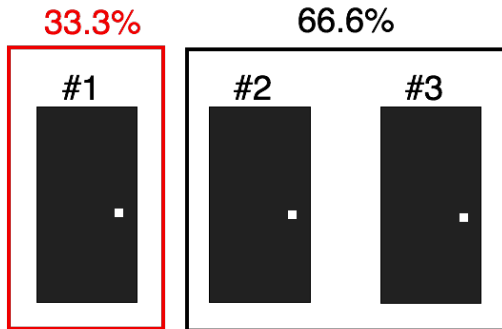
¿Por qué inferencia Bayesiana?

Permite computar creencias óptimas
dadas restricciones: modelos y datos

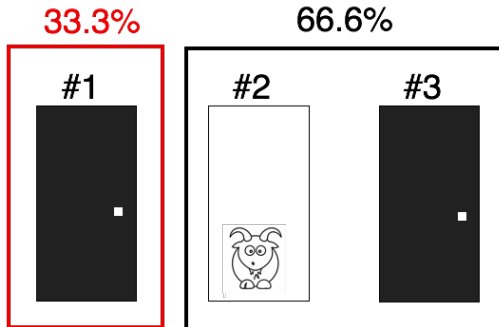
Honestidad: principio de máxima incertidumbre



Honestidad: principio de máxima incertidumbre



Honestidad: principio de máxima incertidumbre



Entropía: la sorpresa fuente de información

Información extraída de la sorpresa,

Entropía: la sorpresa fuente de información

Información extraída de la sorpresa,

$$h(x) = -\log P(x)$$

Entropía: la sorpresa fuente de información

Información extraída de la sorpresa,

$$h(x) = -\log P(x)$$

Información esperada,

Entropía: la sorpresa fuente de información

Información extraída de la sorpresa,

$$h(x) = -\log P(x)$$

Información esperada,

$$H(X) = \sum_x P(x)h(x)$$

Entropía: la sorpresa fuente de información

Información extraída de la sorpresa,

$$h(x) = -\log P(x)$$

Información esperada,

$$H(X) = \sum_x P(x)h(x)$$

Honestidad: máxima entropía

Máxima información esperada \Leftrightarrow Máxima incertidumbre

Entropía: la sorpresa fuente de información

Información extraída de la sorpresa,

$$h(x) = -\log P(x)$$

Información esperada,

$$H(X) = \sum_x P(x)h(x)$$

Honestidad: máxima entropía

Máxima información esperada \Leftrightarrow Máxima incertidumbre

Razonamiento para actualizar creencias

Razonamiento para actualizar creencias

Principios deseable

- Que permita representar las creencias con valores reales

Razonamiento para actualizar creencias

Principios deseable

- Que permita representar las creencias con valores reales
- Que la evidencia cambie las creencias en la dirección del sentido común

Razonamiento para actualizar creencias

Principios deseable

- Que permita representar las creencias con valores reales
- Que la evidencia cambie las creencias en la dirección del sentido común
- Que sea consistente, cualquier camino lleve a la misma conclusión

Razonamiento para actualizar creencias

Principios deseable

- Que permita representar las creencias con valores reales
- Que la evidencia cambie las creencias en la dirección del sentido común
- Que sea consistente, cualquier camino lleve a la misma conclusión

Teorema de Cox, 1946

Las reglas de la probabilidad de Laplace-Jeffreys

Regla de Bernoulli



Estados igualmente posibles: $\{(1, 1), (1, 2), \dots, (6, 6)\}$

Regla de Bernoulli



Estados igualmente posibles: $\{(1, 1), (1, 2), \dots, (6, 6)\}$

$$p(A) = \frac{\text{Cantidad de estados en que } A \text{ es verdadera}}{\text{Cantidad de estados totales}}$$

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

Probabilidad conjunta: $P(X = x_i, Y = y_j) =$

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

Probabilidad conjunta: $P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

Probabilidad conjunta: $P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$

Probabilidad marginal: $P(X = x_i) =$

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

Probabilidad conjunta: $P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$

Probabilidad marginal: $P(X = x_i) = \frac{f_i}{N}$

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

Probabilidad conjunta: $P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$

Probabilidad marginal: $P(X = x_i) = \frac{f_i}{N} = \frac{\sum_j n_{ij}}{N}$

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

Probabilidad conjunta: $P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$

Probabilidad marginal: $P(X = x_i) = \frac{f_i}{N} = \sum_j P(X = x_i, Y = y_j)$

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

Probabilidad conjunta: $P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$

Probabilidad marginal: $P(X = x_i) = \frac{f_i}{N} = \sum_j P(X = x_i, Y = y_j)$

Probabilidad condicional: $P(Y = y_j | X = x_i) =$

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

Probabilidad conjunta: $P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$

Probabilidad marginal: $P(X = x_i) = \frac{f_i}{N} = \sum_j P(X = x_i, Y = y_j)$

Probabilidad condicional: $P(Y = y_j | X = x_i) = \frac{n_{ij}}{f_i}$

La reglas de la probabilidad

	y_j	
x_i	n_{ij}	f_i
	c_j	N

Probabilidad conjunta: $P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$

Probabilidad marginal: $P(X = x_i) = \frac{f_i}{N} = \sum_j P(X = x_i, Y = y_j)$

Probabilidad condicional: $P(Y = y_j | X = x_i) = \frac{n_{ij}}{f_i}$

La reglas de la probabilidad

	y_j			
x_i		n_{ij}		f_i
	c_j			N

Probabilidad conjunta: $P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$

Probabilidad marginal: $P(X = x_i) = \frac{f_i}{N} = \sum_j P(X = x_i, Y = y_j)$

Probabilidad condicional: $P(Y = y_j | X = x_i) = \frac{n_{ij}}{f_i} = \frac{P(X=x_i, Y=y_j)}{P(X=x_i)}$

La reglas de la probabilidad

$$\text{Marginal}_i = \sum_j \text{Conjunta}_{ij}$$

$$\text{Condicional}_{j|i} = \frac{\text{Conjunta}_{ij}}{\text{Marginal}_i}$$

La reglas de la probabilidad

$$\text{Marginal}_i = \sum_j \text{Conjunta}_{ij}$$

$$\text{Condicional}_{j|i} = \frac{\text{Conjunta}_{ij}}{\text{Marginal}_i}$$

Regla de la suma

$$P(X) = \sum_Y P(X, Y)$$

Cualquier distribución marginal puede ser obtenida integrando la distribución conjunta

Regla del producto

$$P(X, Y) = P(Y|X)P(X)$$

Cualquier distribución conjunta puede ser expresada como el producto de distribuciones condicionales unidimensionales.

Teorema de Bayes

$$P(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

Teorema de Bayes

$$P(\text{Creencia} \mid \text{Datos}) = \frac{P(\text{Datos} \mid \text{Creencia})P(\text{Creencia})}{P(\text{Datos})}$$

Teorema de Bayes

$$\underbrace{P(\text{Creencia} \mid \text{Datos})}_{\text{Posteriorii}} = \frac{\overbrace{P(\text{Datos} \mid \text{Creencia})}^{\text{Verosimilitud}} \overbrace{P(\text{Creencia})}^{\text{Priorii}}}{\underbrace{P(\text{Datos})}_{\text{Evidencia}}}$$

Teorema de Bayes

$$\underbrace{P(\text{Creencia} \mid \text{Datos}, \text{Modelo})}_{\text{Posteriorii}} = \frac{\overbrace{P(\text{Datos} \mid \text{Creencia}, \text{Modelo})}^{\text{Verosimilitud}} \overbrace{P(\text{Creencia} \mid \text{Modelo})}^{\text{Priorii}}}{\underbrace{P(\text{Datos} \mid \text{Modelo})}_{\text{Evidencia}}}$$

Teorema de Bayes

$$\underbrace{P(\text{Creencia} \mid \text{Datos}, \text{Modelo})}_{\text{Posteriorii}} = \frac{\overbrace{P(\text{Datos} \mid \text{Creencia}, \text{Modelo})}^{\text{Verosimilitud}} \overbrace{P(\text{Creencia} \mid \text{Modelo})}^{\text{Priorii}}}{\underbrace{P(\text{Datos} \mid \text{Modelo})}_{\text{Evidencia}}}$$

El **modelo** es lo que permite relacionar los **datos** con nuestras **creencias**!

El filtro de las creencias

$$\overbrace{P(C|D, M)}^{\text{Posteriori}} = \frac{\overbrace{P(D|C, M)}^{\text{Verosimilitud}} \overbrace{P(C, M)}^{\text{Priori}}}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$

El filtro de las creencias

$$\overbrace{P(C|D, M)}^{\text{Posteriorii}} = \frac{\overbrace{P(D|C, M)}^{\text{Verosimilitud}} \overbrace{P(C, M)}^{\text{Priorii}}}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$

$$\bullet P(C|M) = \frac{1}{|\text{Creencias}|} \quad \forall C \in \text{Creencias}$$

El filtro de las creencias

$$\overbrace{P(C|D, M)}^{\text{Posteriorii}} = \frac{\overbrace{P(D|C, M)}^{\text{Verosimilitud}} \overbrace{P(C, M)}^{\text{Priorii}}}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$

$$\bullet P(C|M) = \frac{1}{|\text{Creencias}|} \quad \forall C \in \text{Creencias}$$

$$\bullet P(D|C, M) = \frac{\text{Caminos que conducen a } D \text{ dado } C \text{ y } M}{\text{Caminos totales dado } C \text{ and } M} \quad \forall C \in \text{Creencias}$$

El filtro de las creencias

$$\overbrace{P(C|D, M)}^{\text{Posteriorii}} = \frac{\overbrace{P(D|C, M)}^{\text{Verosimilitud}} \overbrace{P(C, M)}^{\text{Priorii}}}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$

$$\bullet P(C|M) = \frac{1}{|\text{Creencias}|} \quad \forall C \in \text{Creencias}$$

$$\bullet P(D|C, M) = \frac{\text{Caminos que conducen a } D \text{ dado } C \text{ y } M}{\text{Caminos totales dado } C \text{ and } M} \quad \forall C \in \text{Creencias}$$

$$\bullet P(D|M) = \sum_{C \in \text{Creencias}} \underbrace{P(D|C, M)}_{\text{Verosimilitud}} \underbrace{P(C|M)}_{\text{Priorii}}$$

El filtro de las creencias

$$\overbrace{P(C|D, M)}^{\text{Posteriorii}} \propto \overbrace{P(D|C, M)}^{\text{Verosimilitud}} \overbrace{P(C, M)}^{\text{Priorii}}$$

$$\bullet P(C|M) = \frac{1}{|\text{Creencias}|} \quad \forall C \in \text{Creencias}$$

$$\bullet P(D|C, M) = \frac{\text{Caminos que conducen a } D \text{ dado } C \text{ y } M}{\text{Caminos totales dado } C \text{ and } M} \quad \forall C \in \text{Creencias}$$

$$\bullet P(D|M) = \sum_{C \in \text{Creencias}} \underbrace{P(D|C, M)}_{\text{Verosimilitud}} \underbrace{P(C|M)}_{\text{Priorii}}$$

El filtro de las creencias

$$\overbrace{P(C|D, M)}^{\text{Posteriorii}} \propto \overbrace{P(D|C, M)}^{\text{Verosimilitud}} \overbrace{P(C, M)}^{\text{Priorii}}$$

- $P(C|M) = \frac{1}{|\text{Creencias}|} \quad \forall C \in \text{Creencias}$
- $P(D|C, M) = \frac{\text{Caminos que conducen a } D \text{ dado } C \text{ y } M}{\text{Caminos totales dado } C \text{ and } M} \quad \forall C \in \text{Creencias}$
- $P(D|M) = \sum_{C \in \text{Creencias}} \underbrace{P(D|C, M)}_{\text{Verosimilitud}} \underbrace{P(C|M)}_{\text{Priorii}}$

Las creencias inverosímiles, se anula.
Las creencias verosímiles, resisten.

La sorpresa: El filtro de las creencias

$$\overbrace{P(C|D, M)}^{\text{Posteriorii}} \propto \overbrace{P(D|C, M)}^{\text{Verosimilitud}} \overbrace{P(C, M)}^{\text{Priorii}}$$

- $P(C|M) = \frac{1}{|\text{Creencias}|} \quad \forall C \in \text{Creencias}$
- $P(D|C, M) = \frac{\text{Caminos que conducen a } D \text{ dado } C \text{ y } M}{\text{Caminos totales dado } C \text{ and } M} \quad \forall C \in \text{Creencias}$
- $P(D|M) = \sum_{C \in \text{Creencias}} \underbrace{P(D|C, M)}_{\text{Verosimilitud}} \underbrace{P(C|M)}_{\text{Priorii}}$

Las creencias inverosímiles, se anula.
Las creencias verosímiles, resisten.

Verosimilitud: el jardín de los caminos que se bifurcan


Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \text{oooo}$

(Primer marcador)

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \text{○○○○}$

(Segundo marcador)

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \text{○○○○}$

(Segundo marcador)

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●


Modelo: $\text{Data} \sim \text{Binomial}(n, p)$



Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \circ \circ \circ \circ$ (Tercer marcador)

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$



Caminos dado M y $C = \text{○ ○ ○ ○}$

Creencia


Caminos que conducen ● ○ ●

○ ○ ○ ○

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$



Caminos dado M y $C = \text{oooo}$

Creencia

Caminos que conducen ● ○ ●


oooo

$0 \times 4 \times 0 = 0$

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \text{oooo}$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto
oooo	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	$1/5$	$\frac{0}{64} \frac{1}{5}$

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \bullet \circ \circ \circ$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto
○ ○ ○ ○	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	1/5	$\frac{0}{64} \frac{1}{5}$
● ○ ○ ○	$1 \times 3 \times 1 = 3$	$\frac{3}{64}$	1/5	$\frac{3}{64} \frac{1}{5}$

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: Data \sim Binomial(n, p)




Caminos dado M y $C = \bullet \bullet \bullet \bullet$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto
○ ○ ○ ○	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	1/5	$\frac{0}{64} \frac{1}{5}$
● ○ ○ ○	$1 \times 3 \times 1 = 3$	3/64	1/5	$\frac{3}{64} \frac{1}{5}$
● ● ○ ○	$2 \times 2 \times 2 = 8$	8/64	1/5	$\frac{8}{64} \frac{1}{5}$

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: Data \sim Binomial(n, p)




Caminos dado M y $C = \bullet \bullet \bullet \bullet$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto
○ ○ ○ ○	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	1/5	$\frac{0}{64} \frac{1}{5}$
● ○ ○ ○	$1 \times 3 \times 1 = 3$	3/64	1/5	$\frac{3}{64} \frac{1}{5}$
● ● ○ ○	$2 \times 2 \times 2 = 8$	8/64	1/5	$\frac{8}{64} \frac{1}{5}$
● ● ● ○	$3 \times 1 \times 3 = 9$	9/64	1/5	$\frac{9}{64} \frac{1}{5}$

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \bullet \bullet \bullet \bullet$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto
○ ○ ○ ○	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	1/5	$\frac{0}{64} \frac{1}{5}$
● ○ ○ ○	$1 \times 3 \times 1 = 3$	3/64	1/5	$\frac{3}{64} \frac{1}{5}$
● ● ○ ○	$2 \times 2 \times 2 = 8$	8/64	1/5	$\frac{8}{64} \frac{1}{5}$
● ● ● ○	$3 \times 1 \times 3 = 9$	9/64	1/5	$\frac{9}{64} \frac{1}{5}$
● ● ● ●	$4 \times 0 \times 4 = 0$	0/64	1/5	$\frac{0}{64} \frac{1}{5}$

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \bullet \bullet \bullet \bullet$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto
○ ○ ○ ○	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	1/5	$\frac{0}{64} \frac{1}{5}$
● ○ ○ ○	$1 \times 3 \times 1 = 3$	$3/64$	1/5	$\frac{3}{64} \frac{1}{5}$
● ● ○ ○	$2 \times 2 \times 2 = 8$	$8/64$	1/5	$\frac{8}{64} \frac{1}{5}$
● ● ● ○	$3 \times 1 \times 3 = 9$	$9/64$	1/5	$\frac{9}{64} \frac{1}{5}$
● ● ● ●	$4 \times 0 \times 4 = 0$	$0/64$	1/5	$\frac{0}{64} \frac{1}{5}$
				$P(D M)$

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \bullet \bullet \bullet \bullet$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto
○ ○ ○ ○	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	1/5	$\frac{0}{64} \cdot \frac{1}{5}$
● ○ ○ ○	$1 \times 3 \times 1 = 3$	$3/64$	1/5	$\frac{3}{64} \cdot \frac{1}{5}$
● ● ○ ○	$2 \times 2 \times 2 = 8$	$8/64$	1/5	$\frac{8}{64} \cdot \frac{1}{5}$
● ● ● ○	$3 \times 1 \times 3 = 9$	$9/64$	1/5	$\frac{9}{64} \cdot \frac{1}{5}$
● ● ● ●	$4 \times 0 \times 4 = 0$	$0/64$	1/5	$\frac{0}{64} \cdot \frac{1}{5}$
				<hr/>
				$\frac{3+8+9}{64 \cdot 5}$

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \bullet \bullet \bullet \bullet$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto	Posteriori
○ ○ ○ ○	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	$1/5$	$\frac{0}{64} \frac{1}{5}$	$\frac{0}{64} \frac{1}{5} \frac{64 \cdot 5}{3+8+9}$
● ○ ○ ○	$1 \times 3 \times 1 = 3$	$3/64$	$1/5$	$\frac{3}{64} \frac{1}{5}$	
● ● ○ ○	$2 \times 2 \times 2 = 8$	$8/64$	$1/5$	$\frac{8}{64} \frac{1}{5}$	
● ● ● ○	$3 \times 1 \times 3 = 9$	$9/64$	$1/5$	$\frac{9}{64} \frac{1}{5}$	
● ● ● ●	$4 \times 0 \times 4 = 0$	$0/64$	$1/5$	$\frac{0}{64} \frac{1}{5}$	
				<hr/>	
				$\frac{3+8+9}{64 \cdot 5}$	

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●

Modelo: $\text{Data} \sim \text{Binomial}(n, p)$




Caminos dado M y $C = \bullet \bullet \bullet \bullet$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto	Posteriori
○ ○ ○ ○	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	1/5	$\frac{0}{64} \cdot \frac{1}{5}$	$\frac{0}{3+8+9} = 0.00$
● ○ ○ ○	$1 \times 3 \times 1 = 3$	$3/64$	1/5	$\frac{3}{64} \cdot \frac{1}{5}$	
● ● ○ ○	$2 \times 2 \times 2 = 8$	$8/64$	1/5	$\frac{8}{64} \cdot \frac{1}{5}$	
● ● ● ○	$3 \times 1 \times 3 = 9$	$9/64$	1/5	$\frac{9}{64} \cdot \frac{1}{5}$	
● ● ● ●	$4 \times 0 \times 4 = 0$	$0/64$	1/5	$\frac{0}{64} \cdot \frac{1}{5}$	
				$\frac{3+8+9}{64 \cdot 5}$	

Verosimilitud: el jardín de los caminos que se bifurcan

Datos: ● ○ ● Creencias: ○ ○ ○ ○, ● ○ ○ ○, ● ● ○ ○, ● ● ● ○, ● ● ● ●


Modelo: $\text{Data} \sim \text{Binomial}(n, p)$



Caminos dado M y $C = \bullet \bullet \bullet \bullet$

Creencia	Caminos que conducen ● ○ ●	Verosimilitud	Priori	Posteriori \propto	Posteriori
○ ○ ○ ○	$0 \times 4 \times 0 = 0$	$\frac{0 \times 4 \times 0}{4 \times 4 \times 4} = \frac{0}{64}$	1/5	$\frac{0}{64} \cdot \frac{1}{5}$	$\frac{0}{3+8+9} = 0.00$
● ○ ○ ○	$1 \times 3 \times 1 = 3$	$3/64$	1/5	$\frac{3}{64} \cdot \frac{1}{5}$	$\frac{3}{3+8+9} = 0.15$
● ● ○ ○	$2 \times 2 \times 2 = 8$	$8/64$	1/5	$\frac{8}{64} \cdot \frac{1}{5}$	$\frac{8}{3+8+9} = 0.40$
● ● ● ○	$3 \times 1 \times 3 = 9$	$9/64$	1/5	$\frac{9}{64} \cdot \frac{1}{5}$	$\frac{9}{3+8+9} = 0.45$
● ● ● ●	$4 \times 0 \times 4 = 0$	$0/64$	1/5	$\frac{0}{64} \cdot \frac{1}{5}$	$\frac{0}{3+8+9} = 0.00$
				<hr/>	
				$\frac{3+8+9}{64 \cdot 5}$	

DE LOS LABERINTOS
SE SALE SÓLO
POR ARRIBA
PITTY




SALE
POR ARRIBA

Modelos gráficos


Modelos gráficos

Rendimiento aleatorio
centrado en la habilidad


Resultado




Modelos gráficos




Modelos gráficos




Modelos gráficos



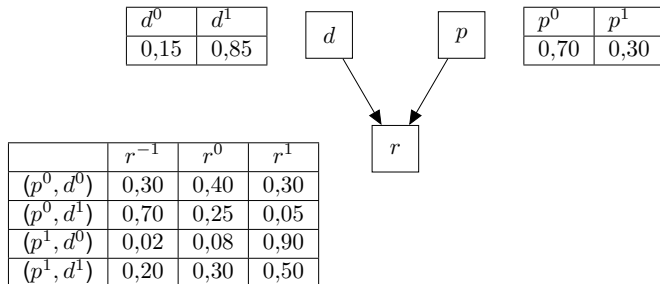
Modelos gráficos



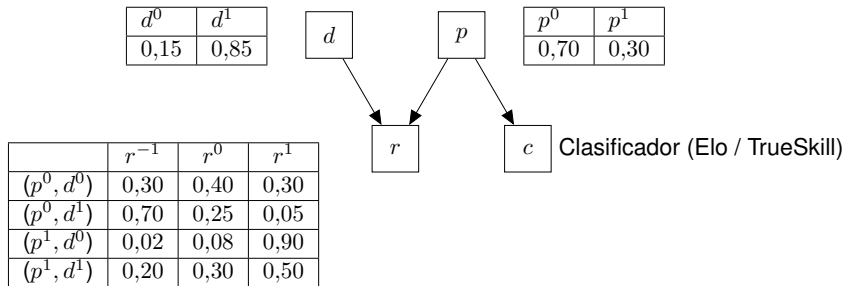
Modelos gráficos



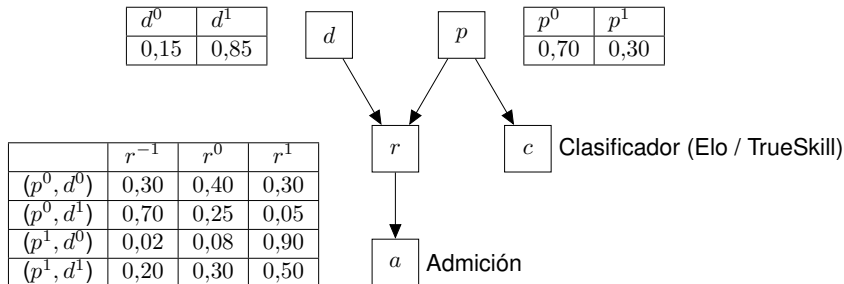
Modelos gráficos



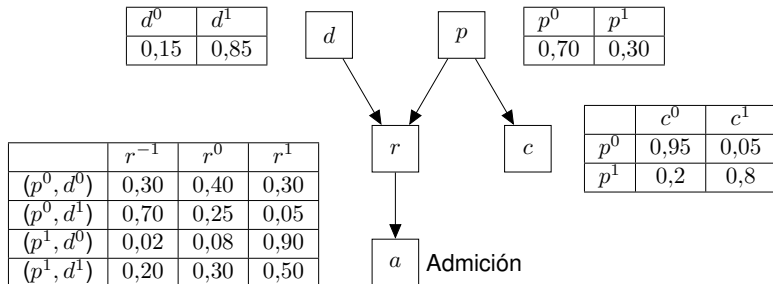
Modelos gráficos




Modelos gráficos



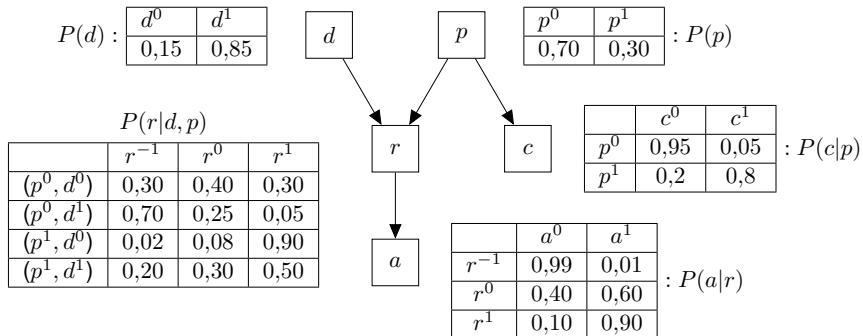
Modelos gráficos




Modelos gráficos



Modelos gráficos

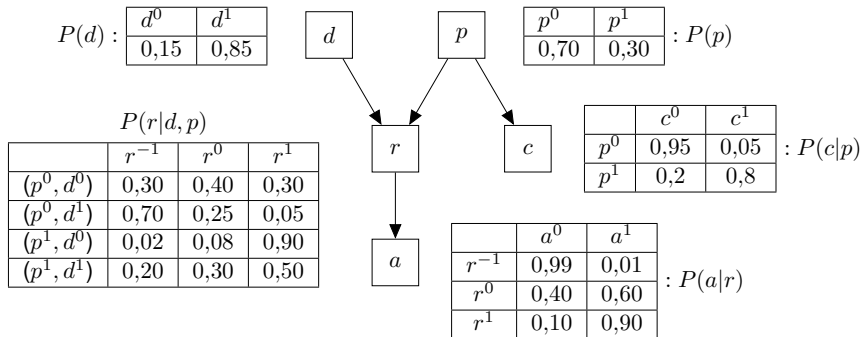


Modelos gráficos




Los factores son útiles para definir distribuciones de probabilidad en espacios de alta dimensión.

Modelos gráficos




$$P(d, p, r, c, a) =$$

Modelos gráficos




$$P(d, p, r, c, a) = P(d)P(p)P(r|d, p)P(c|p)P(a|r)$$

Modelos gráficos




$$P(d^1, p^1, r^1, c^1, a^1) =$$

Modelos gráficos



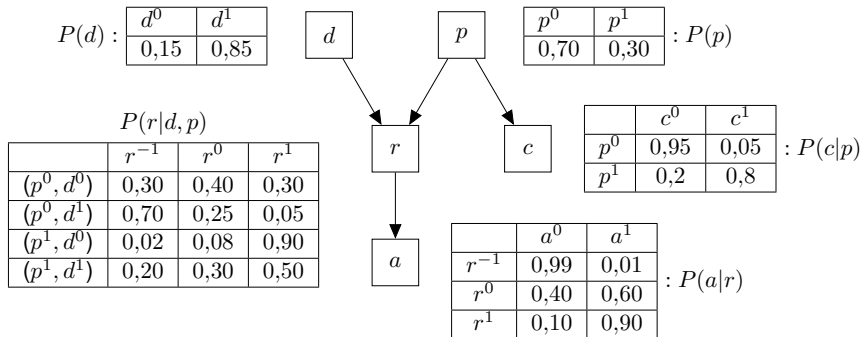
$$P(d^1, p^1, r^1, c^1, a^1) = 0.85 \cdot 0.30 \cdot 0.50 \cdot 0.80 \cdot 0.90$$

Modelos gráficos




$$P(d^1, p^1, r^1, c^1, a^1) = 0,85 \cdot 0,30 \cdot 0,50 \cdot 0,80 \cdot 0,90 \approx 0,09$$

Modelos gráficos




$$P(r^1) =$$

Modelos gráficos




$$P(r^1) = \sum_{i,j,l,m} P(d^i, p^j, r^1, c^l, a^m)$$

Modelos gráficos



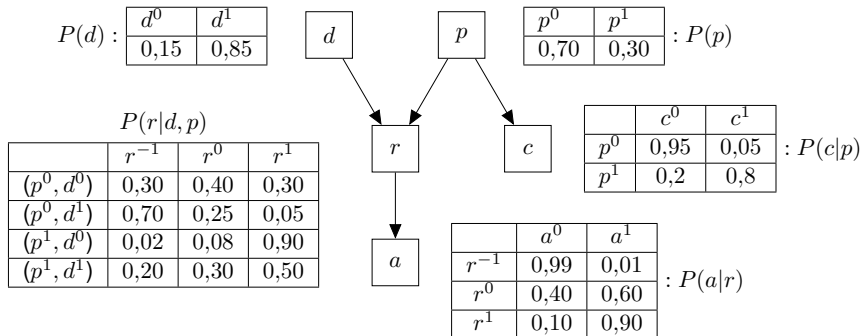
$$P(r^1) = \sum_{i,j,l,m} P(d^i)P(p^j)P(r^1|d^i, p^j)P(c^l|p^j)P(a^m|r^k)$$

Modelos gráficos




$$P(r^1) = \left(\sum_m P(a^m | r^1) \right) \left(\sum_{i,j,l} P(d^i) P(p^j) P(r^1 | d^i, p^j) P(c^l | p^j) \right)$$

Modelos gráficos




$$P(r^1) = \left(\sum_m P(a^m | r^1) \right) \left(\sum_{i,j} P(d^i) P(p^j) P(r^1 | d^i, p^j) \left(\sum_l P(c^l | p^j) \right) \right)$$

Modelos gráficos




$$P(r^1) = \left(\sum_m P(a^m | r^1) \right) \left(\sum_{i,j} P(d^i) P(p^j) P(r^1 | d^i, p^j) \left(\sum_l P(c^l | p^j) \right) \right)$$

Modelos gráficos




$$P(r^1) = \left(\sum_m \cancel{P(a^m|r^1)} \right) \left(\sum_{i,j} P(d^i)P(p^j)P(r^1|d^i,p^j) \left(\sum_l \cancel{P(c^l|p^j)} \right) \right)$$

Modelos gráficos




$$P(r^1) = \sum_{i,j} P(d^i)P(p^j)P(r^1|d^i, p^j)$$

Modelos gráficos



$$P(r^1) = \sum_{i,j} P(d^i)P(p^j)P(r^1|d^i, p^j) \approx 0.18$$

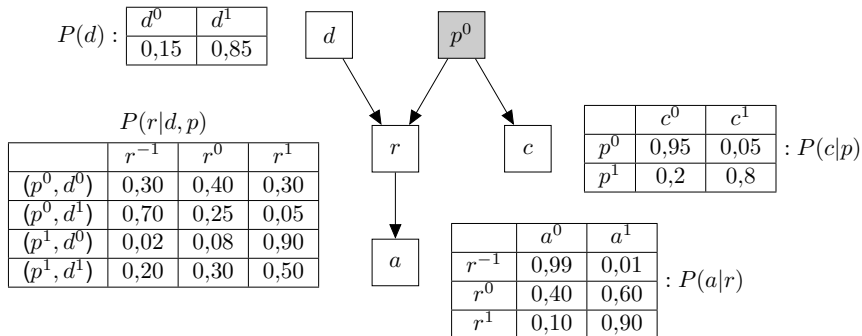
Modelos gráficos



$$P(r^1) = \sum_{i,j} P(d^i)P(p^j)P(r^1|d^i, p^j) \approx 0.18$$

$$P(r^1|p^0) =$$

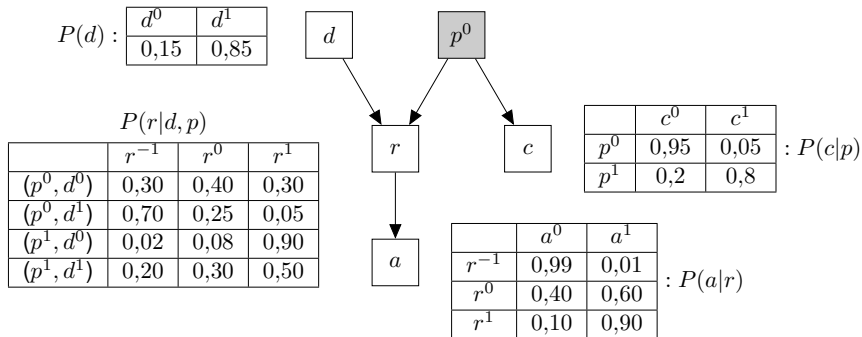
Modelos gráficos



$$P(r^1) = \sum_{i,j} P(d^i)P(p^j)P(r^1|d^i, p^j) \approx 0.18$$

$$P(r^1|p^0) = \frac{P(r^1, p^0)}{P(p^0)}$$


Modelos gráficos



$$P(r^1) = \sum_{i,j} P(d^i)P(p^j)P(r^1|d^i, p^j) \approx 0.18$$

$$P(r^1|p^0) = \frac{1}{P(p^0)} \sum_{i,l,m} P(d^i)P(p^0)P(r^1|d^i, p^0)P(c^l|p^0)P(a^m|r^k)$$


Modelos gráficos



$$P(r^1) = \sum_{i,j} P(d^i)P(p^j)P(r^1|d^i, p^j) \approx 0.18$$

$$P(r^1|p^0) = \frac{1}{P(p^0)} \sum_i P(d^i)P(p^0)P(r^1|d^i, p^0)$$

Modelos gráficos



$$P(r^1) = \sum_{i,j} P(d^i)P(p^j)P(r^1|d^i, p^j) \approx 0.18$$

$$P(r^1|p^0) = \frac{1}{P(p^0)} \sum_i P(d^i)P(p^0)P(r^1|d^i, p^0) \approx 0.13$$

Flujos de inferencia

Flujos de inferencia

$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	
$X \leftarrow V \leftarrow Y$	
$X \leftarrow V \rightarrow Y$	
$X \rightarrow V \leftarrow Y$	

Flujos de inferencia

	$V \notin \text{Observable}$ Sí	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$		
$X \leftarrow V \leftarrow Y$		
$X \leftarrow V \rightarrow Y$		
$X \rightarrow V \leftarrow Y$		

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	
$X \leftarrow V \leftarrow Y$	Sí	
$X \leftarrow V \rightarrow Y$		
$X \rightarrow V \leftarrow Y$		

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	
$X \leftarrow V \leftarrow Y$	Sí	
$X \leftarrow V \rightarrow Y$	Sí	
$X \rightarrow V \leftarrow Y$		

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	
$X \leftarrow V \leftarrow Y$	Sí	
$X \leftarrow V \rightarrow Y$	Sí	
$X \rightarrow V \leftarrow Y$	No	

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	No
$X \leftarrow V \leftarrow Y$	Sí	
$X \leftarrow V \rightarrow Y$	Sí	
$X \rightarrow V \leftarrow Y$	No	

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	No
$X \leftarrow V \leftarrow Y$	Sí	No
$X \leftarrow V \rightarrow Y$	Sí	
$X \rightarrow V \leftarrow Y$	No	

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	No
$X \leftarrow V \leftarrow Y$	Sí	No
$X \leftarrow V \rightarrow Y$	Sí	No
$X \rightarrow V \leftarrow Y$	No	

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	No
$X \leftarrow V \leftarrow Y$	Sí	No
$X \leftarrow V \rightarrow Y$	Sí	No
$X \rightarrow V \leftarrow Y$	No	Sí

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	No
$X \leftarrow V \leftarrow Y$	Sí	No
$X \leftarrow V \rightarrow Y$	Sí	No
$X \rightarrow V \leftarrow Y$	No	Sí
		O algún descendiente observable

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	No
$X \leftarrow V \leftarrow Y$	Sí	No
$X \leftarrow V \rightarrow Y$	Sí	No
$X \rightarrow V \leftarrow Y$	No	Sí
	Y ningún descendiente observable	O algún descendiente observable

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	No
$X \leftarrow V \leftarrow Y$	Sí	No
$X \leftarrow V \rightarrow Y$	Sí	No
$X \rightarrow V \leftarrow Y$	No	Sí
	Y ningún descendiente observable	O algún descendiente observable

Un flujo de inferencia permanece abierto si:

- Toda consecuencia común (o alguno de sus descendientes) es observable
- Ninguna otra variable es observable

Flujos de inferencia

	$V \notin \text{Observable}$	$V \in \text{Observable}$
$X \rightarrow V \rightarrow Y$	Sí	No
$X \leftarrow V \leftarrow Y$	Sí	No
$X \leftarrow V \rightarrow Y$	Sí	No
$X \rightarrow V \leftarrow Y$	No	Sí
	Y ningún descendiente observable	O algún descendiente observable


Un flujo de inferencia permanece abierto si:

- Toda consecuencia común (o alguno de sus descendientes) es observable
- Ninguna otra variable es observable

TrueSkill



TrueSkill



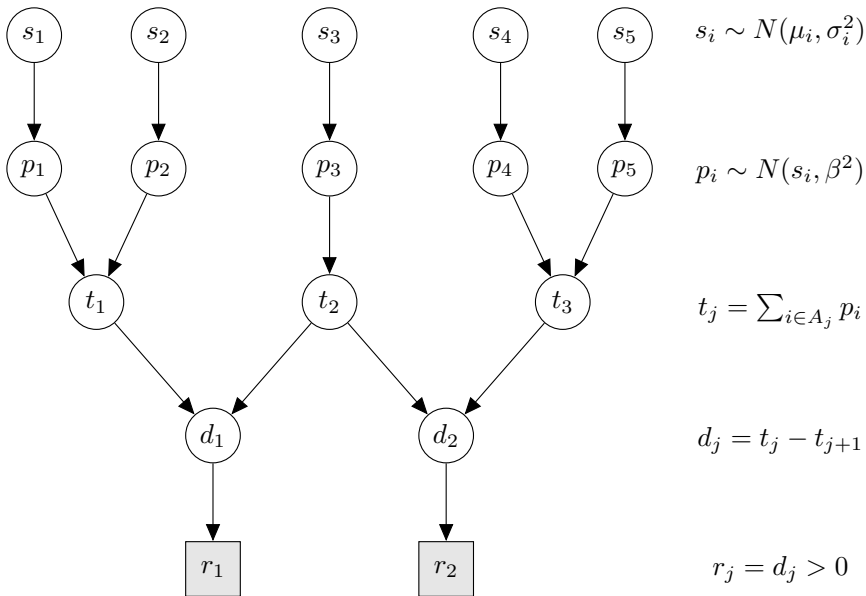
$$s_i \sim N(\mu_i, \sigma_i^2)$$


$$p_i \sim N(s_i, \beta^2)$$

$$t_e = \sum_{i \in A_e} p_i$$

$$d_j = t_{o_j} - t_{o_{j+1}}$$

$$r_j = d_j > 0$$





Factor graph


$$g(x_1, \dots, x_n) = \prod f_j(X)$$

Factor graph

$$g(x_1, x_2, x_3, x_4, x_5) = f_A(x_1)f_B(x_2)f_C(x_1, x_2, x_3)f_D(x_3, x_4)f_E(x_3, x_5)$$


Factor graph

$$g(x_1, x_2, x_3, x_4, x_5) = f_A(x_1)f_B(x_2)f_C(x_1, x_2, x_3)f_D(x_3, x_4)f_E(x_3, x_5)$$



Factor graph

$$g(x_1, x_2, x_3, x_4, x_5) = f_A(x_1)f_B(x_2)f_C(x_1, x_2, x_3)f_D(x_3, x_4)f_E(x_3, x_5)$$




Un factor graph sin ciclos codifica:

- La factorización de una función $g(x_1, \dots, x_n)$

Factor graph

$$g(x_1, x_2, x_3, x_4, x_5) = f_A(x_1)f_B(x_2)f_C(x_1, x_2, x_3)f_D(x_3, x_4)f_E(x_3, x_5)$$



Un factor graph sin ciclos codifica:


- La factorización de una función $g(x_1, \dots, x_n)$
- **Las operaciones para computar sus marginales $g_i(x_i)$**

Ejemplo

$$g_1(x_1) = \sum_{x_2} \sum_{x_3} \sum_{x_4} \sum_{x_5} f_A(x_1) f_B(x_2) f_C(x_1, x_2, x_3) f_D(x_3, x_4) f_E(x_3, x_5)$$


Ejemplo

$$g_1(x_1) = \sum_{x_2} \sum_{x_3} \sum_{x_4} \sum_{x_5} f_A(x_1) f_B(x_2) f_C(x_1, x_2, x_3) f_D(x_3, x_4) f_E(x_3, x_5)$$



Ejemplo


$$g_1(x_1) = \sum_{x_2} \sum_{x_3} \sum_{x_4} \sum_{x_5} f_A(x_1) f_B(x_2) f_C(x_1, x_2, x_3) f_D(x_3, x_4) f_E(x_3, x_5)$$



$$g_1(x_1) = f_A(x_1) \left(\sum_{x_2, x_3} f_B(x_2) f_C(x_1, x_2, x_3) \left(\sum_{x_4} f_D(x_3, x_4) \right) \left(\sum_{x_5} f_E(x_3, x_5) \right) \right)$$


Ejemplo

$$g_3(x_3) = \sum_{x_1} \sum_{x_2} \sum_{x_4} \sum_{x_5} f_A(x_1) f_B(x_2) f_C(x_1, x_2, x_3) f_D(x_3, x_4) f_E(x_3, x_5)$$



Ejemplo

$$g_3(x_3) = \sum_{x_1} \sum_{x_2} \sum_{x_4} \sum_{x_5} f_A(x_1) f_B(x_2) f_C(x_1, x_2, x_3) f_D(x_3, x_4) f_E(x_3, x_5)$$




$$g_3(x_3) = \left(\sum_{x_1, x_2} f_A(x_1) f_B(x_2) f_C(x_1, x_2, x_3) \right) \left(\sum_{x_4} f_D(x_3, x_4) \right) \left(\sum_{x_5} f_E(x_3, x_5) \right)$$

Sum-product algorithm

$m_{x \rightarrow f}(x)$: Mensaje enviado por el nodo variable x al nodo factor f

$m_{f \rightarrow x}(x)$: Mensaje enviado por un nodo factor f a un nodo variable x .

$n(v)$: Conjunto de nodos vecinos a v .




$$g_i(x_i) = \prod_{h \in n(x_i)} m_{h \rightarrow x_i}$$

Sum-product algorithm

$m_{x \rightarrow f}(x)$: Mensaje enviado por el nodo variable x al nodo factor f

$m_{f \rightarrow x}(x)$: Mensaje enviado por un nodo factor f a un nodo variable x .

$n(v)$: Conjunto de nodos vecinos a v .



$$g_i(x_i) = \prod_{h \in n(x_i)} m_{h \rightarrow x_i}$$


$$m_{x \rightarrow f}(x) = \prod_{h \in n(x) \setminus \{f\}} m_{h \rightarrow x}(x) \quad (1)$$

Sum-product algorithm

$m_{x \rightarrow f}(x)$: Mensaje enviado por el nodo variable x al nodo factor f

$m_{f \rightarrow x}(x)$: Mensaje enviado por un nodo factor f a un nodo variable x .

$n(v)$: Conjunto de nodos vecinos a v .



$$g_i(x_i) = \prod_{h \in n(x_i)} m_{h \rightarrow x_i}$$

$$m_{x \rightarrow f}(x) = \prod_{h \in n(x) \setminus \{f\}} m_{h \rightarrow x}(x) \quad (1)$$


$$m_{f \rightarrow x}(x) = \sum_{X \setminus \{x\}} \left(f(X) \prod_{h \in n(f) \setminus \{x\}} m_{h \rightarrow f}(h) \right) \quad (2)$$

Sum-product algorithm

$m_{x \rightarrow f}(x)$: Mensaje enviado por el nodo variable x al nodo factor f

$m_{f \rightarrow x}(x)$: Mensaje enviado por un nodo factor f a un nodo variable x .

$n(v)$: Conjunto de nodos vecinos a v .




$$g_i(x_i) = \prod_{h \in n(x_i)} m_{h \rightarrow x_i}$$

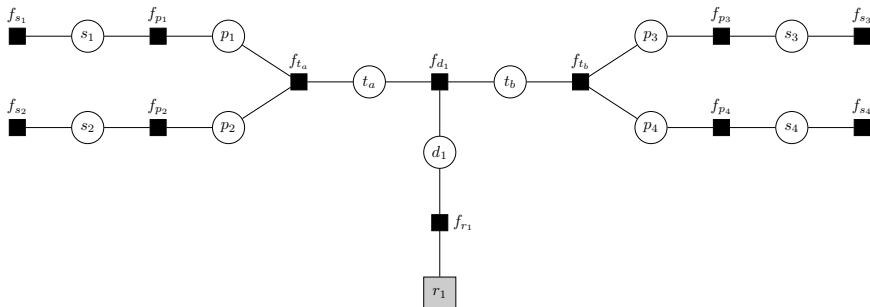

$$m_{x \rightarrow f}(x) = \prod_{h \in n(x) \setminus \{f\}} m_{h \rightarrow x}(x) \quad (1)$$

$$m_{f \rightarrow x}(x) = \sum_{X \setminus \{x\}} \left(f(X) \prod_{h \in n(f) \setminus \{x\}} m_{h \rightarrow f}(h) \right) \quad (2)$$

TrueSkill



TrueSkill



Propiedades

$$N(x|\mu, \sigma^2) = N(\mu|x, \sigma^2) = N(-\mu|-x, \sigma^2) = N(-x|-\mu, \sigma^2) \quad (3)$$

Propiedades

$$N(x|\mu, \sigma^2) = N(\mu|x, \sigma^2) = N(-\mu|-x, \sigma^2) = N(-x|-\mu, \sigma^2) \quad (3)$$

$$N(x|\mu, \sigma^2) = N\left(\frac{X - \mu}{\sigma} | 0, 1\right) \quad (4)$$

Propiedades

$$N(x|\mu, \sigma^2) = N(\mu|x, \sigma^2) = N(-\mu|-x, \sigma^2) = N(-x|-\mu, \sigma^2) \quad (3)$$

$$N(x|\mu, \sigma^2) = N\left(\frac{X - \mu}{\sigma} | 0, 1\right) \quad (4)$$

$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = N(x|\mu, \sigma^2) \quad (5)$$

Propiedades

$$N(x|\mu, \sigma^2) = N(\mu|x, \sigma^2) = N(-\mu|-x, \sigma^2) = N(-x|-\mu, \sigma^2) \quad (3)$$

$$N(x|\mu, \sigma^2) = N\left(\frac{X - \mu}{\sigma} | 0, 1\right) \quad (4)$$

$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = N(x|\mu, \sigma^2) \quad (5)$$

$$\iint_{-\infty}^{\infty} \mathbb{I}(x = h(y, z)) f(x) g(y) dx dy = \int_{-\infty}^{\infty} f(h(y, z)) g(y) dy \quad (6)$$

Propiedades


$$N(x|\mu, \sigma^2) = N(\mu|x, \sigma^2) = N(-\mu|-x, \sigma^2) = N(-x|-\mu, \sigma^2) \quad (3)$$

$$N(x|\mu, \sigma^2) = N\left(\frac{X - \mu}{\sigma} | 0, 1\right) \quad (4)$$


$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = N(x|\mu, \sigma^2) \quad (5)$$

$$\iint_{-\infty}^{\infty} \mathbb{I}(x = h(y, z)) f(x) g(y) dx dy = \int_{-\infty}^{\infty} f(h(y, z)) g(y) dy \quad (6)$$


$$\int_{-\infty}^{\infty} N(x|\mu_x, \sigma_x^2) N(x|\mu_y, \sigma_y^2) dx \stackrel{*}{=} \int_{-\infty}^{\infty} \underbrace{N(\mu_x|\mu_y, \sigma_x^2 + \sigma_y^2)}_{\text{constante}} \underbrace{N(x|\mu_*, \sigma_*^2)}_{\text{integra 1}} dx \quad (7)$$




$$m_{f_{s_i} \rightarrow s_i}(s_i) =$$



$$m_{f_{s_i} \rightarrow s_i}(s_i) = \int f_{s_i}(\mathbf{x}) \prod_{h \in n(f_{s_i}) \setminus \{s_i\}} m_{h \rightarrow f_{s_i}}(h) d\mathbf{x}_{\setminus \{s_i\}}$$

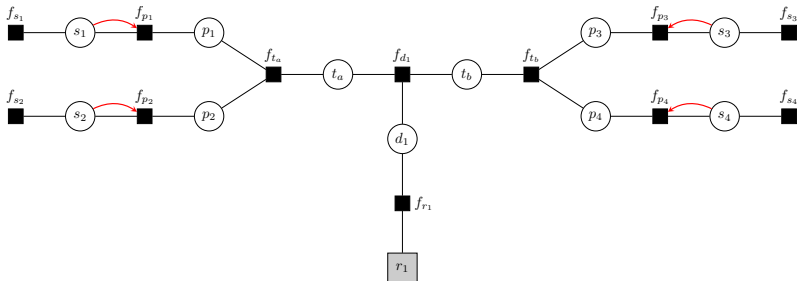


$$m_{f_{s_i} \rightarrow s_i}(s_i) = \int N(s_i | \mu_i, \sigma_i^2) d\mathbf{x}_{\setminus \{s_i\}}$$




$$m_{f_{s_i} \rightarrow s_i}(s_i) = \int N(s_i | \mu_i, \sigma_i^2) d\mathbf{x}_{\setminus \{s_i\}} = N(s_i | \mu_i, \sigma_i^2)$$


$$m_{s \rightarrow f_p}(s)$$



$$m_{s_i \rightarrow f_{p_i}}(s_i) =$$

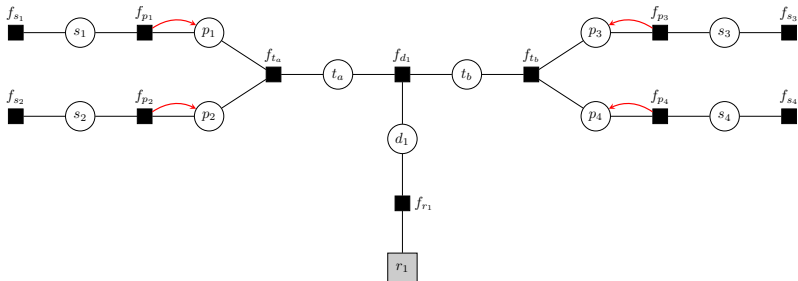


$$m_{s_i \rightarrow f_{p_i}}(s_i) = \prod_{h \in n(s_i) \setminus \{f_{p_i}\}} m_{h \rightarrow s_i}(s_i)$$




$$m_{s_i \rightarrow f_{p_i}}(s_i) = N(s_i | \mu_i, \sigma_i^2)$$

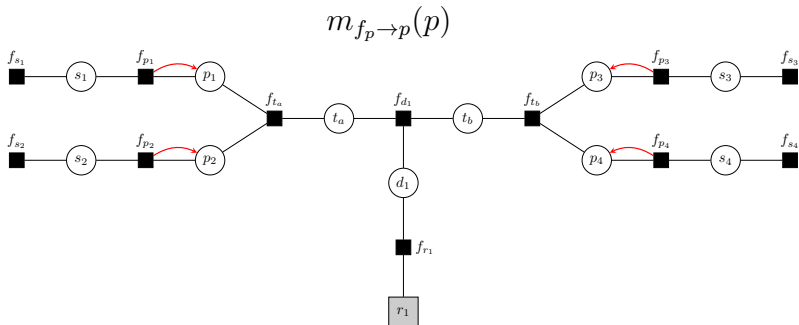
$$m_{f_p \rightarrow p}(p)$$




$$m_{f_{p_i} \rightarrow p_i}(p_i) =$$




$$m_{f_{p_i} \rightarrow p_i}(p_i) = \int f_{p_i}(\mathbf{x}) \left(\prod_{h \in n(f_{p_i}) \setminus \{p_i\}} m_{h \rightarrow f_{p_i}}(h) \right) d\mathbf{x}_{\setminus \{p_i\}}$$




$$m_{f_{p_i} \rightarrow p_i}(p_i) = \int N(p_i | s_i, \beta^2) N(s_i | \mu_i, \sigma_i^2) ds_i$$



$$m_{f_{p_i} \rightarrow p_i}(p_i) = \int N(p_i | s_i, \beta^2) N(s_i | \mu_i, \sigma_i^2) ds_i = \int N(s_i | p_i, \beta^2) N(s_i | \mu_i, \sigma_i^2) ds_i$$

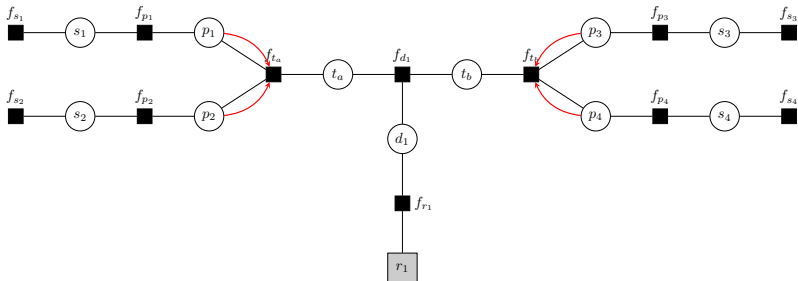


$$\begin{aligned}
 m_{f_{p_i} \rightarrow p_i}(p_i) &= \int N(p_i | s_i, \beta^2) N(s_i | \mu_i, \sigma_i^2) ds_i = \int N(s_i | p_i, \beta^2) N(s_i | \mu_i, \sigma_i^2) ds_i \\
 &= \int \underbrace{N(p_i | \mu_i, \beta^2 + \sigma_i^2)}_{\text{const.}} \underbrace{N(s_i | \mu_*, \sigma_*^2)}_1 ds_i
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{p_i} \rightarrow p_i}(p_i) &= \int N(p_i | s_i, \beta^2) N(s_i | \mu_i, \sigma_i^2) ds_i = \int N(s_i | p_i, \beta^2) N(s_i | \mu_i, \sigma_i^2) ds_i \\
 &= \int \underbrace{N(p_i | \mu_i, \beta^2 + \sigma_i^2)}_{\text{const.}} \underbrace{N(s_i | \mu_*, \sigma_*^2)}_1 ds_i \\
 &= N(p_i | \mu_i, \beta^2 + \sigma_i^2)
 \end{aligned}$$


$$m_{p \rightarrow f_t}(p)$$




$$m_{p_i \rightarrow f_{t_e}}(p_i) =$$




$$m_{p_i \rightarrow f_{t_e}}(p_i) = \prod_{h \in n(p_i) \setminus \{f_{t_e}\}} m_{h \rightarrow p_i}(p_i)$$




$$m_{p_i \rightarrow f_{t_e}}(p_i) = \prod_{i \in e} N(p_i | \mu_i, \beta^2 + \sigma_i^2)$$




$$m_{f_{t_e} \rightarrow t_e}(t_e) =$$




$$m_{f_{t_e} \rightarrow t_e}(t_e) = \int f_{t_e}(\mathbf{x}) \left(\prod_{h \in n(f_{t_e}) \setminus \{t_e\}} m_{h \rightarrow f_{t_e}}(h) \right) d\mathbf{x}_{\setminus \{t_e\}}$$




$$m_{f_{t_e} \rightarrow t_e}(t_e) = \iint \mathbb{I}(t_e = p_i + p_j) N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j$$




$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(t_e - p_i | \mu_j, \beta^2 + \sigma_j^2) dp_i
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_i | t_e - \mu_j, \beta^2 + \sigma_j^2) dp_i
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_i | t_e - \mu_j, \beta^2 + \sigma_j^2) dp_i \\
 &= \int \underbrace{N(t_e | \mu_i + \mu_j, 2\beta^2 + \sigma_i^2 + \sigma_j^2)}_{\text{const.}} \underbrace{N(p_i | \mu_*, \sigma_*^2)}_1 dp_i
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_i | t_e - \mu_j, \beta^2 + \sigma_j^2) dp_i \\
 &= N(t_e | \mu_i + \mu_j, 2\beta^2 + \sigma_i^2 + \sigma_j^2)
 \end{aligned}$$



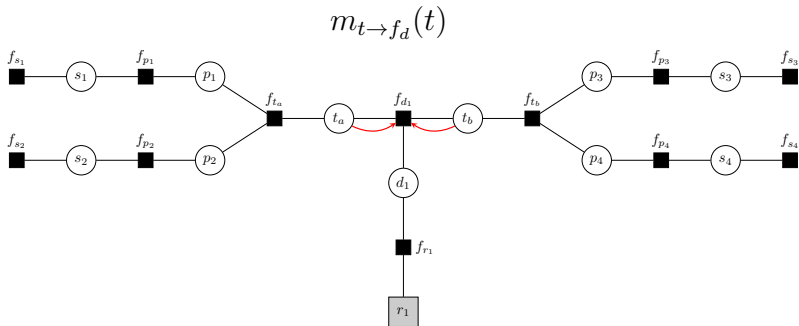
$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_i | t_e - \mu_j, \beta^2 + \sigma_j^2) dp_i \\
 &= N(t_e | \sum_{i \in A_e} \mu_i, \sum_{i \in A_e} \beta^2 + \sigma_i^2)
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int N(p_i | \mu_i, \beta^2 + \sigma_i^2) N(p_i | t_e - \mu_j, \beta^2 + \sigma_j^2) dp_i \\
 &= N(t_e | \sum_{i \in A_e} \mu_i, \sum_{i \in A_e} \beta^2 + \sigma_i^2) = N(t_e | \mu_e, \sigma_e^2)
 \end{aligned}$$




$$m_{t_e \rightarrow f_d}(t_e) =$$




$$m_{t_e \rightarrow f_d}(t_e) = \prod_{h \in n(t_e) \setminus \{f_d\}} m_{h \rightarrow t_e}(t_e)$$




$$m_{t_e \rightarrow f_d}(t_e) = N(t_e | \mu_e, \sigma_e^2)$$




$$m_{f_d \rightarrow d}(d) =$$




$$m_{f_d \rightarrow d}(d) = \int f_d(\mathbf{x}) \left(\prod_{h \in n(f_d) \setminus \{d\}} m_{h \rightarrow f_d}(h) \right) d\mathbf{x}_{\setminus \{d\}}$$




$$m_{f_d \rightarrow d}(d) = \iint \mathbb{I}(d = t_a - t_b) N(t_a | \mu_a, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_a dt_b$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) N(t_a | \mu_a, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int N(d + t_b | \mu_a, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_b
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) N(t_a | \mu_a, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int N(t_b | \mu_a - d, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_b
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) N(t_a | \mu_a, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int N(t_b | \mu_a - d, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \int \underbrace{N(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)}_{\text{const.}} \underbrace{N(t_b | \mu_*, \sigma_*^2)}_1 dt_b
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) N(t_a | \mu_a, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int N(t_b | \mu_a - d, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= N(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) N(t_a | \mu_a, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int N(t_b | \mu_a - d, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= N(d | \underbrace{\mu_a - \mu_b}_{\text{Diferencia esperada } \delta}, \underbrace{\sigma_a^2 + \sigma_b^2}_{\text{Varianza total } \vartheta})
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) N(t_a | \mu_a, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int N(t_b | \mu_a - d, \sigma_a^2) N(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= N(d | \underbrace{\mu_a - \mu_b}_{\text{Diferencia esperada } \delta}, \underbrace{\sigma_a^2 + \sigma_b^2}_{\text{Varianza total } \vartheta}) = N(d | \delta, \vartheta^2)
 \end{aligned}$$



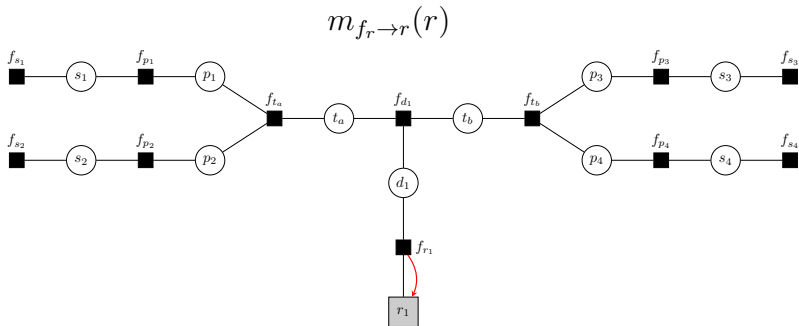
$$m_{t_e \rightarrow f_d}(t_e) =$$




$$m_{t_e \rightarrow f_d}(t_e) = N(d|\delta, \vartheta^2)$$




$$m_{f_r \rightarrow r}(r) =$$




$$m_{f_r \rightarrow r}(r) = \int \mathbb{I}(d > 0) N(d | \delta, \vartheta^2) dd$$




$$\begin{aligned}
 m_{f_r \rightarrow r}(r) &= \int \mathbb{I}(d > 0) N(d|\delta, \vartheta^2) dd \\
 &= \int_0^\infty N(d|\delta, \vartheta^2) dd
 \end{aligned}$$





$$\begin{aligned}
 m_{f_r \rightarrow r}(r) &= \int \mathbb{I}(d > 0) N(d|\delta, \vartheta^2) dd \\
 &= \int_0^\infty N(d|\delta, \vartheta^2) dd
 \end{aligned}$$






$$\begin{aligned}
 m_{f_r \rightarrow r}(r) &= \int \mathbb{I}(d > 0) N(d|\delta, \vartheta^2) dd \\
 &= \int_0^{\infty} N(d|\delta, \vartheta^2) dd \\
 &= 1 - \Phi(0|\delta, \vartheta^2)
 \end{aligned}$$






$$\begin{aligned}
 m_{f_r \rightarrow r}(r) &= \int \mathbb{I}(d > 0) N(d|\delta, \vartheta^2) dd \\
 &= \int_0^\infty N(d|\delta, \vartheta^2) dd \\
 &= 1 - \Phi(0|\delta, \vartheta^2) = \Phi\left(\frac{\delta}{\vartheta}\right)
 \end{aligned}$$




Evidencia


$$P(r|s, A) = \Phi\left(\frac{\delta}{\vartheta}\right) \quad (8)$$




$$m_{f_r \rightarrow d}(d) =$$



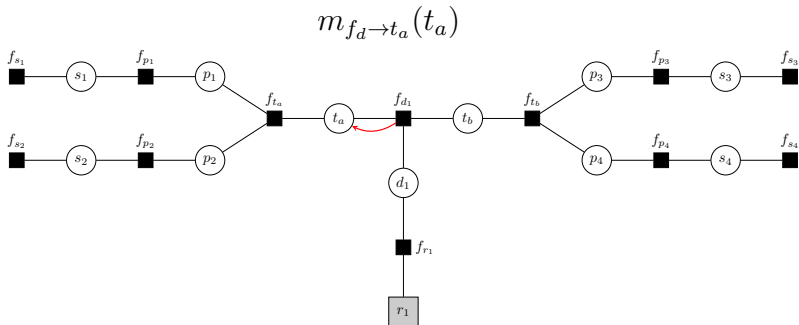
$$m_{f_r \rightarrow d}(d) = \mathbb{I}(d > 0)$$




$$m_{f_d \rightarrow t_a}(t_a) =$$




$$m_{f_d \rightarrow t_a}(t_a) = \iint \mathbb{I}(d = t_a - t_b) \mathbb{I}(d > 0) N(t_b | \mu_b, \sigma_b^2) dt_b dd$$




$$m_{f_d \rightarrow t_a}(t_a) = \int \mathbb{I}(t_a > t_b) N(t_b | \mu_b, \sigma_b^2) dt_b dd$$




$$m_{f_d \rightarrow t_a}(t_a) = \int \mathbb{I}(t_a > t_b) N(t_b | \mu_b, \sigma_b^2) dt_b dd$$

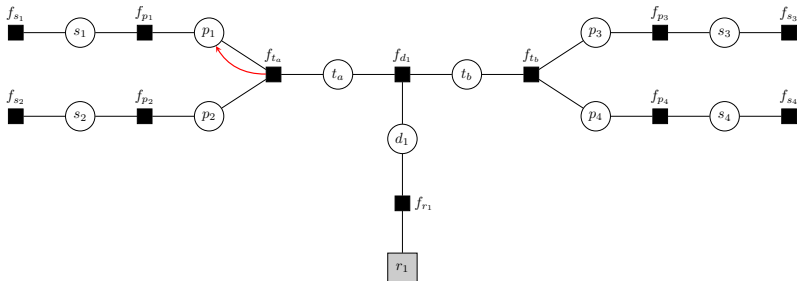





$$\begin{aligned}
 m_{f_d \rightarrow t_a}(t_a) &= \int \mathbb{I}(t_a > t_b) N(t_b | \mu_b, \sigma_b^2) dt_b dd \\
 &= \Phi(t_a | \mu_b, \sigma_b^2)
 \end{aligned}$$



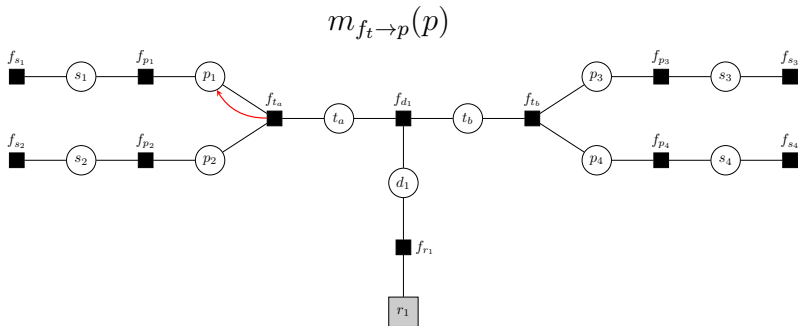
$$m_{f_t \rightarrow p}(p)$$



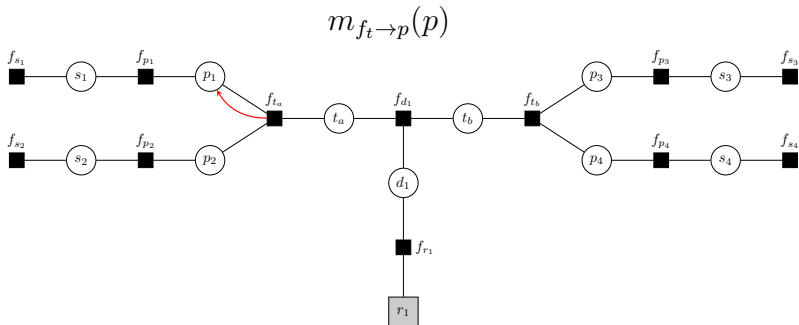
$$m_{f_{t_a} \rightarrow p_1}(p_1) =$$




$$m_{f_{t_a} \rightarrow p_1}(p_1) = \iint \mathbb{I}(t_a = p_1 + p_2) N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(t_a | \mu_b, \sigma_b^2) dt_a dp_2$$



$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 + p_2 | \mu_b, \sigma_b^2) dp_2$$

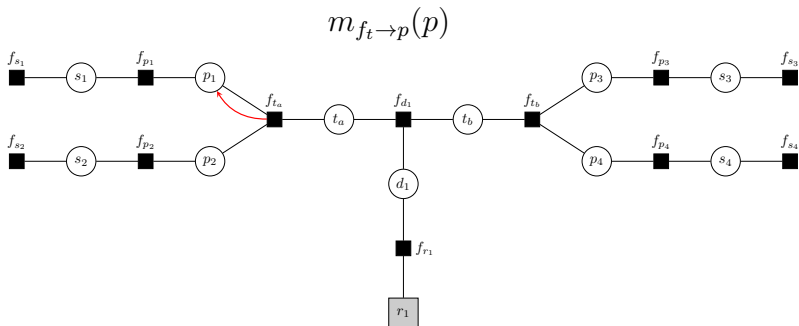


$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$




$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \frac{\partial}{\partial p_1} \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$



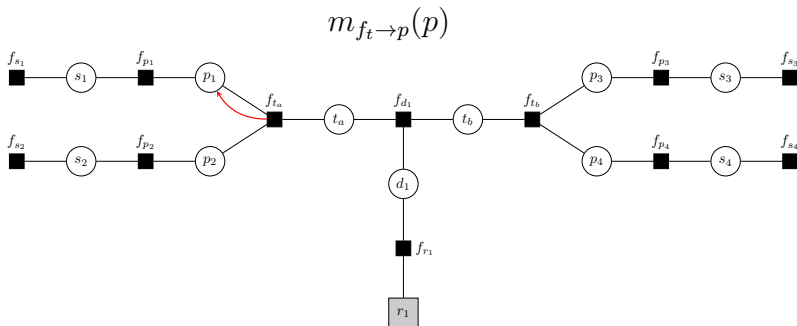
$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \frac{\partial}{\partial p_1} \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$



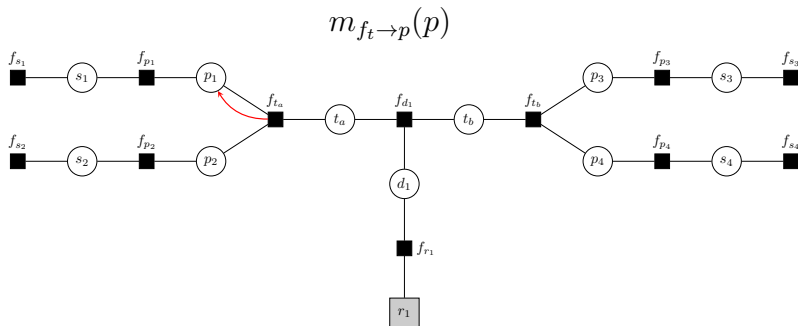
$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) N(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$



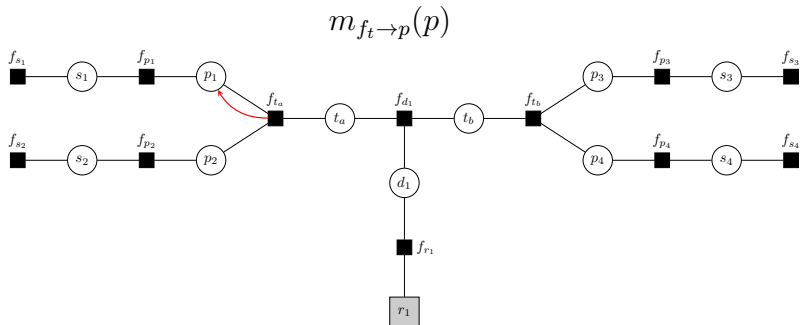
$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) N(p_2 | \mu_b - p_1, \sigma_b^2) dp_2$$




$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \int \underbrace{N(\mu_2 | \mu_b - p_1, \sigma_b^2 + \sigma_2^2 + \beta^2)}_{\text{const.}} \underbrace{N(p_2 | \mu_*, \sigma_*^2)}_1 dp_2$$



$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

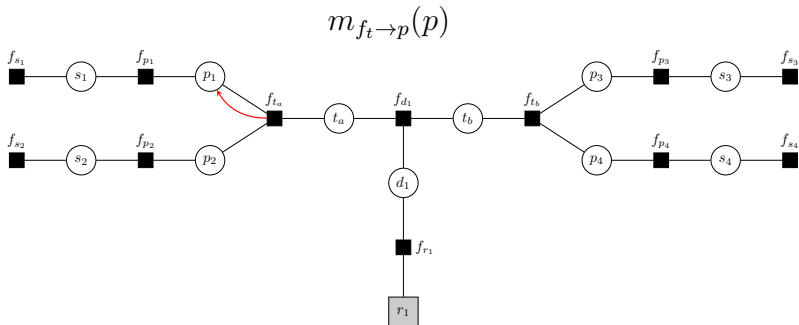
$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = N(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2)$$



$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = N(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2)$$

$$m_{f_{t_a} \rightarrow p_1}(p_1) =$$

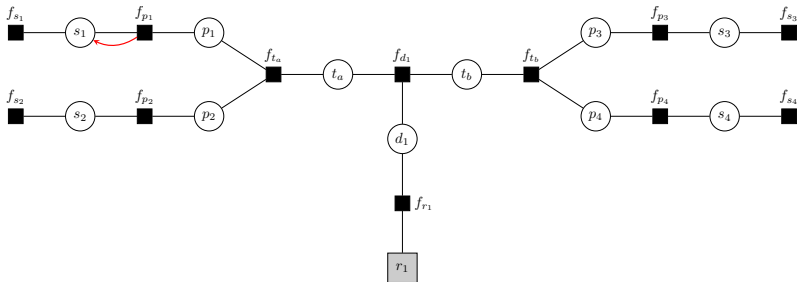


$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int N(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$


$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = N(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2)$$

$$m_{f_{t_a} \rightarrow p_1}(p_1) = \Phi(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2)$$


$$m_{f_p \rightarrow s}(s)$$



$$m_{f_{p_1} \rightarrow s_1}(s_1) =$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int N(p_1 | s_1, \beta^2) \Phi(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$



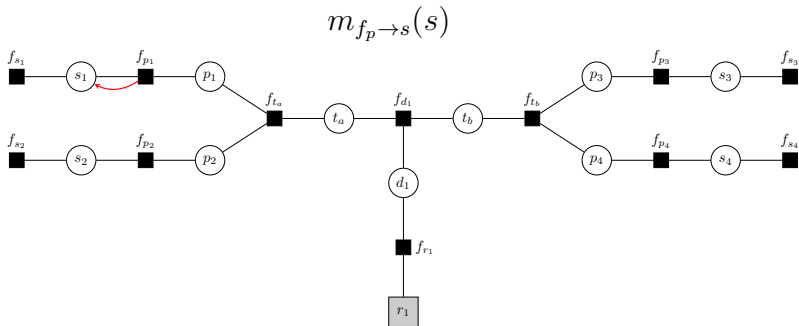
$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int N(p_1 | s_1, \beta^2) \Phi(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$

$$\frac{\partial}{\partial \mu_2} m_{f_{s_1} \rightarrow s_1}(s_1) =$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int N(p_1 | s_1, \beta^2) \Phi(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$

$$\frac{\partial}{\partial \mu_2} m_{f_{s_1} \rightarrow s_1}(s_1) = \int N(p_1 | s_1, \beta^2) N(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$



$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int N(p_1 | s_1, \beta^2) \Phi(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$


$$\frac{\partial}{\partial \mu_2} m_{f_{p_1} \rightarrow s_1}(s_1) = N(s_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int N(p_1 | s_1, \beta^2) \Phi(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$

$$\frac{\partial}{\partial \mu_2} m_{f_{s_1} \rightarrow s_1}(s_1) = N(s_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$


$$m_{f_{p_1} \rightarrow s_1}(s_1) = \Phi(s_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \Phi(s_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \Phi(s_1 | \mu_b - \underbrace{\mu_2}_{\mu_a - \mu_1}, \sigma_b^2 + \underbrace{\sigma_2^2 + 2\beta^2}_{\sigma_a^2 - \sigma_1^2})$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \Phi(s_1 | \mu_b - \mu_a + \mu_1, \sigma_b^2 + \sigma_a^2 - \sigma_1^2)$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \Phi(s_1 | \underbrace{\mu_b - \mu_a}_{-\delta} + \mu_1, \underbrace{\sigma_b^2 + \sigma_a^2}_{\vartheta^2} - \sigma_1^2)$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \Phi(s_1 | -\delta + \mu_1, \vartheta^2 - \sigma_1^2)$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \Phi(0 | -\delta + \mu_1 - s_1, \vartheta^2 - \sigma_1^2)$$



$$\begin{aligned}
 m_{f_{p_1} \rightarrow s_1}(s_1) &= \Phi(0 | -\delta + \mu_1 - s_1, \vartheta^2 - \sigma_1^2) \\
 &= 1 - \Phi(0 | \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)
 \end{aligned}$$



$$\begin{aligned}
 m_{f_{p_1} \rightarrow s_1}(s_1) &= \Phi(0 \mid -\delta + \mu_1 - s_1, \vartheta^2 - \sigma_1^2) \\
 &= 1 - \Phi(0 \mid \underbrace{\delta - \mu_1 + s_1}_{\text{Diferencia esperada parametrizada en } s}, \underbrace{\vartheta^2 - \sigma_1^2}_{\text{Sin incertidumbre respecto de } s})
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{p_1} \rightarrow s_1}(s_1) &= \Phi(0 \mid -\delta + \mu_1 - s_1, \vartheta^2 - \sigma_1^2) \\
 &= 1 - \Phi\left(0 \mid \underbrace{\delta - \mu_1 + s_1}_{\text{Diferencia esperada parametrizada en } s}, \underbrace{\vartheta^2 - \sigma_1^2}_{\text{Sin incertidumbre respecto de } s}\right)
 \end{aligned}$$


= Probabilidad de ganar si la verdadera habilidad fuera s_1

$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Priori}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$


$$\overbrace{P(s_1 | r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_1 | \mu_1, \sigma_1^2)}^{\text{Priori}} \overbrace{1 - \Phi(0 | \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 | r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_1 | \mu_1, \sigma_1^2)}^{\text{Priori}} \overbrace{1 - \Phi(0 | \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 | r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_1 | \mu_1, \sigma_1^2)}^{\text{Priori}} \overbrace{1 - \Phi(0 | \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 | r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_1 | \mu_1, \sigma_1^2)}^{\text{Priori}} \overbrace{1 - \Phi(0 | \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 | r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_1 | \mu_1, \sigma_1^2)}^{\text{Priori}} \overbrace{1 - \Phi(0 | \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 | r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_1 | \mu_1, \sigma_1^2)}^{\text{Priori}} \overbrace{1 - \Phi(0 | \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$



$$\overbrace{P(s_3 \mid r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_3 \mid \mu_3, \sigma_3^2)}^{\text{Priori}} \overbrace{\Phi(0 \mid \delta + \mu_3 - s_3, \vartheta^2 - \sigma_3^2)}^{\text{Verosimilitud}} \quad \text{Caso perdedor}$$



$$\overbrace{P(s_3 \mid r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_3 \mid \mu_3, \sigma_3^2)}^{\text{Priori}} \overbrace{\Phi(0 \mid \delta + \mu_3 - s_3, \vartheta^2 - \sigma_3^2)}^{\text{Verosimilitud}} \quad \text{Caso perdedor}$$



Selección de modelo

¿Y nuestras creencias respecto de modelos alternativos?

Selección de modelo

$$P(M|D) = \frac{P(D|M)P(M)}{P(D)}$$

Selección de modelo

$$P(M|D) = \frac{P(D|M)P(M)}{P(D)}$$

$$\frac{P(M_i|D)}{P(M_j|D)} = \frac{P(D|M_i) P(M_i)}{P(D|M_j) P(M_j)}$$

Selección de modelo

$$P(M|D) = \frac{P(D|M)P(M)}{P(D)}$$

$$\frac{P(M_i|D)}{P(M_j|D)} = \frac{P(D|M_i) P(M_i)}{\underbrace{P(D|M_j) P(M_j)}_{\text{Evidencia!}}}$$

Selección de modelo

$$P(M|D) = \frac{P(D|M)P(M)}{P(D)}$$

$$\frac{P(M_i|D)}{P(M_j|D)} = \frac{P(D|M_i) \cancel{P(M_i)}}{\underbrace{P(D|M_j)}_{\text{Evidencia!}} \cancel{P(M_j)}}$$

Selección de modelo

$$P(M|D) = \frac{P(D|M)P(M)}{P(D)}$$

$$\frac{P(M_i|D)}{P(M_j|D)} = \frac{P(D|M_i) \cancel{P(M_i)}}{\underbrace{P(D|M_j)}_{\text{Evidencia!}} \cancel{P(M_j)}}$$

Lo único que necesitamos es la **evidencia!**

Selección de modelo

$$P(M|D) = \frac{P(D|M)P(M)}{P(D)}$$

$$\frac{P(M_i|D)}{P(M_j|D)} = \frac{P(D|M_i) \cancel{P(M_i)}}{\underbrace{P(D|M_j)}_{\text{Evidencia!}} \cancel{P(M_j)}}$$

Lo único que necesitamos es la **evidencia!**

Evidencia

$$P(C|D, M) = \frac{P(D|C, M)P(C|M)}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$

Evidencia

$$P(C|D, M) = \frac{P(D|C, M)P(C|M)}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$

$$P(D|M) = \sum_C P(D|C, M) P(C|M)$$

Evidencia

$$P(C|D, M) = \frac{P(D|C, M)P(C|M)}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$

$$P(D|M) = \sum_C \underbrace{P(D|C, M)}_{\text{Predicción de D dado C}} \underbrace{P(C|M)}_{\text{Creencia de C a Priori}}$$

Evidencia

$$P(C|D, M) = \frac{P(D|C, M)P(C|M)}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$

$$P(D|M) = \sum_C \underbrace{P(D|C, M)}_{\substack{\text{Predicción} \\ \text{de D dado C}}} \underbrace{P(C|M)}_{\substack{\text{Creencia de} \\ \text{C a Priori}}}$$

Predicción de la datos observados
pesando todas las creencias a priori

Evidencia

$$P(C|D, M) = \frac{P(D|C, M)P(C|M)}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$

$$P(D|M) = \sum_C \underbrace{P(D|C, M)}_{\substack{\text{Predicción} \\ \text{de D dado C}}} \underbrace{P(C|M)}_{\substack{\text{Creencia de} \\ \text{C a Priori}}}$$

Predicción de la datos observados
pesando todas las creencias a priori

Preferimos modelos con la menor **sorpres**a en la evidencia!

Evidencia

$$P(C|D, M) = \frac{P(D|C, M)P(C|M)}{\underbrace{P(D|M)}_{\text{Evidencia}}}$$


$$P(D|M) = \sum_C \underbrace{P(D|C, M)}_{\substack{\text{Predicción} \\ \text{de D dado C}}} \underbrace{P(C|M)}_{\substack{\text{Creencia de} \\ \text{C a Priori}}}$$

Predicción de la datos observados
pesando todas las creencias a priori

Preferimos modelos con la menor **sorpres**a en la evidencia!


$$P(M_q|D) > P(M_r|D) \iff P(D|M_q) > P(D|M_r)$$

Evidencia




Balance natural entre complejidad y predicción


Función objetivo



Función objetivo




Modelos polinomiales



Evidencia vs Verosimilitud

Evidencia conjunta



Máxima verosimilitud

